

# 高速缓存一致性和 量化分析



作者姓名： 高帅

邮箱： [gshuai@mail.ustc.edu.cn](mailto:gshuai@mail.ustc.edu.cn)

版本时间： 二〇二〇年七月二十日

## 写在最开始

缓存一致性 (Cache Coherent) 一直是芯片架构设计的重要问题，该文章配合仓库中的项目，来实现各种各样的 Cache 系统并比较 Cache 系统在特定场景下的性能。

本人毕业从事 AI 芯片架构设计岗位的工作，缓存一致性系统作为自己一个重要的技能栈，会广泛的学习各种发表或者开源的项目，加深自己对存储子系统的理解，服务于自己的设计工作。

## 目 录

第 1 章 基础知识	1
1.1 引言	1
1.2 存储器层次结构	1
1.3 缓存优化与方法	1
1.3.1 1	1
1.3.2 2	1
1.3.3 3	1
1.4 存储区优化与技术	1
1.4.1 二级节标题	1
1.5 脚注	1
第 2 章 浮动体	2
2.1 三线表	2
2.2 插图	2
2.3 算法环境	3
第 3 章 数学	4
3.1 数学符号和公式	4
3.2 量和单位	4
3.3 定理和证明	5
第 4 章 交叉问题	7
4.1 数学符号和公式	7
第 5 章 引用文献的标注	8
5.1 顺序编码制	8
5.1.1 角标数字标注法	8
5.1.2 数字标注法	8
5.2 著者-出版年制标注法	8
参考文献	9
附录 A 存储器层次结构回顾	10
A.1 缓存及缓存性能	10



## 第1章 基础知识

### 1.1 引言

### 1.2 存储器层次结构

### 1.3 缓存优化与方法

#### 1.3.1 1

#### 1.3.2 2

#### 1.3.3 3

### 1.4 存储区优化与技术

#### 1.4.1 二级节标题

#### 1. 三级节标题

##### (1) 四级节标题

##### ① 五级节标题

### 1.5 脚注

内容<sup>①</sup>

---

<sup>①</sup>脚注

## 第2章 浮 动 体

### 2.1 三线表

三线表是《撰写手册》推荐使用的格式，如表 2.1。

表 2.1 表号和表题在表的正上方

类型	描述
挂线表	挂线表也称系统表、组织表，用于表现系统结构
无线表	无线表一般用于设备配置单、技术参数列表等
卡线表	卡线表有完全表，不完全表和三线表三种

注：表注分两种，第一种是对全表的注释，用不加阿拉伯数字排在表的下边，前面加“注：”；第二种是和表内的某处文字或数字相呼应的注，在表里面用带圈的阿拉伯数字在右上角标出，然后在表下面用同样的圈码注出来

编制表格应简单明了，表达一致，明晰易懂，表文呼应、内容一致。排版时表格字号略小，或变换字体，尽量不分页，尽量不跨节。表格太大需要转页时，需要在续表上方注明“续表”，表头页应重复排出。

### 2.2 插图

有的同学可能听说“ $\text{\LaTeX}$  只能使用 eps 格式的图片”，甚至把 jpg 格式转为 eps。事实上，这种做法已经过时。而且每次编译时都要调用外部工具解析 eps，导致降低编译速度。所以我们推荐矢量图直接使用 pdf 格式，位图使用 jpeg 或 png 格式。



图 2.1 图号、图题置于图的下方

注：图注的内容不宜放到图题中。

关于图片的并排，推荐使用较新的 `subcaption` 宏包，不建议使用 `subfigure`

或 `subfig` 等宏包。

## 2.3 算法环境

模板中使用 `algorithm2e` 宏包实现算法环境。关于该宏包的具体用法，请阅读宏包的官方文档。

---

### 算法 2.1 算法示例 1

---

**Data:** this text

**Result:** how to write algorithm with L<sup>A</sup>T<sub>E</sub>X2e

```
1 initialization;
2 while not at end of this document do
3   read current;
4   if understand then
5     go to next section;
6     current section becomes this one;
7   else
8     go back to the beginning of current section;
9   end
10 end
```

---

注意，我们可以在论文中插入算法，但是插入大段的代码是愚蠢的。然而这并不妨碍有的同学选择这么做，对于这些同学，建议用 `listings` 宏包。

## 第3章 数 学

### 3.1 数学符号和公式

《撰写手册》要求数学符号要根据 GB/T 3102.11-1993 《物理科学和技术中使用的数学符号》<sup>①</sup> 使用，这与 L<sup>A</sup>T<sub>E</sub>X 默认的英美国家的数学符号习惯有所差异。本模板基于 `unicode-math` 宏包配置数学符号，以遵循国标的规定：

1. 大写希腊字母默认为斜体，如 `\Delta`： $\Delta$ 。
2. 有限增量符号  $\Delta$  (U+2206) 应使用 `\increment` 命令。
3. 向量、矩阵和张量要求粗斜体，应使用 `\sympbf` 命令，如 `\sympbf{A}`、`\sympbf{\alpha}`。
4. 数学常数和特殊函数使用正体，如圆周率  $\pi$ 、 $\Gamma$  函数。应使用 `unicode-math` 宏包提供的 `\symup` 命令转为正体，如 `\symup{\pi}`。
5. 微分符号  $d$  使用正体，本模板提供了 `\dif` 命令。

注意，`unicode-math` 宏包与 `amsfonts`、`amssymb`、`bm`、`mathrsfs`、`upgreek` 等宏包不兼容。本模板作了处理，用户可以直接使用 `\bm`、`\mathscr`、`\upGamma`。关于数学符号更多的用法，参见 `unicode-math` 宏包的使用说明和符号列表 `unimath-symbols`。

在编辑数学公式时，最好避免直接使用字体命令，而应该定义一些语义命令取代字体命令，这样输入更简单，也让 L<sup>A</sup>T<sub>E</sub>X 代码更有可读性，而且还方便根据需要统一修改改格式。参考示例文档中的 `math-commands.tex`

更多的例子：

$$e^{i\pi} + 1 = 0 \quad (3.1)$$

$$\frac{d^2 u}{dt^2} = \int f(x) dx \quad (3.2)$$

$$\arg \min_x f(x) \quad (3.3)$$

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x} \quad (3.4)$$

### 3.2 量和单位

宏包 `siunitx` 提供了更好的数字和单位支持：

- 12 345.678 90
- $1 \pm 2i$

<sup>①</sup>原 GB 3102.11-1993，根据 2017 年第 7 号公告和强制性标准整合精简结论，自 2017 年 3 月 23 日起，该标准转化为推荐性标准。



- $0.3 \times 10^{45}$
- $1.654 \times 2.34 \times 3.430$
- $\text{kg} \cdot \text{m} \cdot \text{s}^{-1}$
- $\mu\text{m} \mu\text{m}$
- $\Omega \Omega$
- 10 和 20
- 10, 20 和 30
- 0.13 mm, 0.67 mm 和 0.80 mm
- $10 \sim 20$
- $10^\circ\text{C} \sim 20^\circ\text{C}$

### 3.3 定理和证明

示例文件中使用 `amsthm` 宏包配置了定理、引理和证明等环境。用户也可以使用 `ntheorem` 宏包。

**定义 3.1** If the integral of function  $f$  is measurable and non-negative, we define its (extended) **Lebesgue integral** by

$$\int f = \sup_g \int g, \quad (3.5)$$

where the supremum is taken over all measurable functions  $g$  such that  $0 \leq g \leq f$ , and where  $g$  is bounded and supported on a set of finite measure.

**假设 3.1** The communication graph is strongly connected.

**例 3.1** Simple examples of functions on  $\mathbf{R}^d$  that are integrable (or non-integrable) are given by

$$f_a(x) = \begin{cases} |x|^{-a} & \text{if } |x| \leq 1, \\ 0 & \text{if } |x| > 1. \end{cases} \quad (3.6)$$

$$F_a(x) = \frac{1}{1 + |x|^a}, \quad \text{all } x \in \mathbf{R}^d. \quad (3.7)$$

Then  $f_a$  is integrable exactly when  $a < d$ , while  $F_a$  is integrable exactly when  $a > d$ .

**引理 3.1 (Fatou)** Suppose  $\{f_n\}$  is a sequence of measurable functions with  $f_n \geq 0$ . If  $\lim_{n \rightarrow \infty} f_n(x) = f(x)$  for a.e.  $x$ , then

$$\int f \leq \liminf_{n \rightarrow \infty} \int f_n. \quad (3.8)$$

**注** We do not exclude the cases  $\int f = \infty$ , or  $\liminf_{n \rightarrow \infty} \int f_n = \infty$ .

**推论 3.2** Suppose  $f$  is a non-negative measurable function, and  $\{f_n\}$  a sequence of non-negative measurable functions with  $f_n(x) \leq f(x)$  and  $f_n(x) \rightarrow f(x)$  for almost every  $x$ . Then

$$\lim_{n \rightarrow \infty} \int f_n = \int f. \quad (3.9)$$

**命题 3.3** Suppose  $f$  is integrable on  $\mathbf{R}^d$ . Then for every  $\epsilon > 0$ :

i. There exists a set of finite measure  $B$  (a ball, for example) such that

$$\int_{B^c} |f| < \epsilon. \quad (3.10)$$

ii. There is a  $\delta > 0$  such that

$$\int_E |f| < \epsilon \quad \text{whenever } m(E) < \delta. \quad (3.11)$$

**定理 3.4** Suppose  $\{f_n\}$  is a sequence of measurable functions such that  $f_n(x) \rightarrow f(x)$  a.e.  $x$ , as  $n$  tends to infinity. If  $|f_n(x)| \leq g(x)$ , where  $g$  is integrable, then

$$\int |f_n - f| \rightarrow 0 \quad \text{as } n \rightarrow \infty, \quad (3.12)$$

and consequently

$$\int f_n \rightarrow \int f \quad \text{as } n \rightarrow \infty. \quad (3.13)$$

**证明** Trivial. □

**Axiom of choice** Suppose  $E$  is a set and  $E_\alpha$  is a collection of non-empty subsets of  $E$ . Then there is a function  $\alpha \mapsto x_\alpha$  (a “choice function”) such that

$$x_\alpha \in E_\alpha, \quad \text{for all } \alpha. \quad (3.14)$$

**Observation 1** Suppose a partially ordered set  $P$  has the property that every chain has an upper bound in  $P$ . Then the set  $P$  contains at least one maximal element.

**A concise proof** Obvious. □

## 第4章 交叉问题

### 4.1 数学符号和公式

## 第 5 章 引用文献的标注

模板使用 `natbib` 宏包来设置参考文献引用的格式，更多引用方法可以参考该宏包的使用说明。

### 5.1 顺序编码制

#### 5.1.1 角标数字标注法

<code>\cite{knuth86a}</code>	$\Rightarrow$	[1]
<code>\citet{knuth86a}</code>	$\Rightarrow$	Knuth <sup>[1]</sup>
<code>\cite[42]{knuth86a}</code>	$\Rightarrow$	[1] <sup>42</sup>
<code>\cite{knuth86a,tlc2}</code>	$\Rightarrow$	[1-2]
<code>\cite{knuth86a, knuth84}</code>	$\Rightarrow$	[1,3]

#### 5.1.2 数字标注法

<code>\cite{knuth86a}</code>	$\Rightarrow$	[1]
<code>\citet{knuth86a}</code>	$\Rightarrow$	Knuth [1]
<code>\cite[42]{knuth86a}</code>	$\Rightarrow$	[1] <sup>42</sup>
<code>\cite{knuth86a,tlc2}</code>	$\Rightarrow$	[1-2]
<code>\cite{knuth86a, knuth84}</code>	$\Rightarrow$	[1, 3]

### 5.2 著者-出版年制标注法

<code>\cite{knuth86a}</code>	$\Rightarrow$	Knuth (1986)
<code>\citep{knuth86a}</code>	$\Rightarrow$	(Knuth, 1986)
<code>\citet[42]{knuth86a}</code>	$\Rightarrow$	Knuth (1986) <sup>42</sup>
<code>\citep[42]{knuth86a}</code>	$\Rightarrow$	(Knuth, 1986) <sup>42</sup>
<code>\cite{knuth86a,tlc2}</code>	$\Rightarrow$	Knuth (1986); Mittelbach et al. (2004)
<code>\cite{knuth86a, knuth84}</code>	$\Rightarrow$	Knuth (1986, 1984)

注意，参考文献列表中的每条文献在正文中都要被引用<sup>[4-19]</sup>。

## 参 考 文 献

- [1] KNUTH D E. Computers and typesetting: A the  $\text{\TeX}$ book [M]. Reading, MA, USA: Addison-Wesley, 1986.
- [2] MITTELBAACH F, GOOSSENS M, BRAAMS J, et al. The  $\text{\LaTeX}$  companion [M]. 2nd ed. Reading, MA, USA: Addison-Wesley, 2004.
- [3] KNUTH D E. Literate programming [J]. The Computer Journal, 1984, 27(2): 97-111.
- [4] 孙立广. 顶级期刊论文摘要汇编 (1999–2010) [G]. 合肥: 中国科学技术大学出版社, 2016: 222.
- [5] 李泳池. 张量初步和近代连续介质力学概论 [M]. 2 版. 合肥: 中国科学技术大学出版社, 2016: 61.
- [6] 刘景双. 湿地生态系统碳、氮、硫、磷生物地球化学过程 [M]. 合肥: 中国科学技术大学出版社, 2014.
- [7] 程根伟. 1998 年长江洪水的成因与减灾对策 [M]//许厚泽, 赵其国. 长江流域洪涝灾害与科技对策. 北京: 科学出版社, 1999: 26-32.
- [8] 陈晋镡, 张惠民, 朱士兴, 等. 蓟县震旦亚界研究 [M]//中国地质科学院天津地质矿产研究所. 中国震旦亚界. 天津: 天津科学技术出版社, 1980: 56-114.
- [9] 孔庆勇, 郭红健, 孔庆和. 我国科技期刊的金字塔分层模型及发展路径初探 [J]. 中国科技期刊研究, 2015, 26(10): 1100-1103.
- [10] 杨洪升. 四库馆私家抄校书考略 [J]. 文献, 2013(1): 56-75.
- [11] 于潇, 刘义, 柴跃廷, 等. 互联网药品可信交易环境中主体资质审核备案模式 [J]. 清华大学学报 (自然科学版), 2012, 52(11): 1518-1521.
- [12] 丁文洋. 数字革命与竞争国际化 [N]. 中国青年报, 2000-11-20(15).
- [13] 姜锡洲. 一种温热外敷药制备方案: 中国, 88105607.3 [P]. 1989-07-26.
- [14] 万锦坤. 中国大学学报论文文摘 (1983–1993) (英文版) [DB/CD]. 北京: 中国大百科全书出版社, 1996.
- [15] 孙玉文. 汉语变调构词研究 [D]. 北京: 北京大学, 2000.
- [16] 文富, 顾丽梅. 网络时代经济发展战略特征 [J]. 学术研究, 2000, 21(4): 35-40.
- [17] 肖度, 等. 知识时代的企业合作经营 [M]. 北京: 北京大学出版社, 2000: 67-69.
- [18] The White House. Technology for economic growth [R]. Washington, 1993.
- [19] HUTSON J M. Vibrational dependence of the anisotropic intermolecular potential of argon-hydrogen chloride [J]. J. Phys. Chem., 1992, 96(11): 4237-4247.

## 附录 A 存储器层次结构回顾

**缓存：**地址离开处理器后遇到的最高一级或第一级存储器层次结构，局部性原理支撑了缓存的高性能的理论逻辑。其中**时间局部性**指当前访问的数据在不久的将来极有可能还会再次用到，**空间局部性**指当前用到的数据附近的数据（同一个数据块）也极有可能用到。

**虚拟存储器：**一些数据可以存储在磁盘上，地址空间被划分为固定大小的块（页），任何时候页要么在主存储器上，要么在磁盘上。当地址页不在缓存也不再主存储器上时发生页错误，要把整个页从磁盘加载到主存储器上。页错误消耗的时间过长，处理器一般会切换任务。

### A.1 缓存及缓存性能

## 附录 B 存储器层次结构回顾